Desafíos Técnicos en Big Data

[Módulo 1 · Sesión 1 · Día 2]

Procesamiento Big Data con Scala

01

BLOQUE TEÓRICO

Desafíos técnicos en el manejo de Big Data

📋 Agenda — Sesión 1

🧠 Bloque Teórico

- Retos de almacenamiento: distribuido vs. tradicional
- Retos de procesamiento: latencia, throughput y tolerancia a fallos
- Retos de análisis: calidad, integracion y heterogeneidad
- Infraestructura: On-Premise vs. Cloud

💻 Bloque Práctico

- Practica 1: Identificar cuellos de botella en arquitecturas
- Practica 2: Comparativa HDFS vs. almacenamiento tradicional
- Practica 3: Quiz de comprension sobre los conceptos del dia

¿Por que los sistemas tradicionales no son suficientes?

El mundo genera cada dia mas de 2,5 exabytes de datos. Las bases de datos relacionales y los discos duros tradicionales fueron disenados para otro mundo.

Limitaciones de los sistemas tradicionales:

- Escalado vertical (mas RAM, mas CPU): tiene un limite fisico y es muy caro
- Un unico servidor es un punto unico de fallo — si cae, todo se cae
- SQL clasico no fue disenado para datos no estructurados (imagenes, logs, JSON)
- El procesamiento en batch no sirve para responder en tiempo real

Solucion: distribuir datos y procesamiento entre muchas maquinas (cluster)

Retos de Almacenamiento: Distribuido vs. Tradicional

Almacenar terabytes o petabytes de datos es el primer gran reto del Big Data.

Almacenamiento tradicional (escala vertical):

- Un solo servidor con discos: RAID, NAS, SAN
- Barato para pocos datos, pero tiene limite fisico de capacidad
- Si el disco falla, los datos pueden perderse

Almacenamiento distribuido HDFS (escala horizontal):

- Los datos se dividen en bloques de 128 MB y se reparten entre muchas maquinas
- Cada bloque se replica 3 veces: si un nodo falla, los datos siguen disponibles
- Escalar = anadir mas nodos al cluster, no comprar servidores mas caros

Clave: HDFS fue disenado para ficheros grandes (no millones de ficheros pequenos)

Retos de Procesamiento: Latencia, Throughput y Tolerancia a Fallos

Procesar millones de registros por segundo exige arquitecturas que los sistemas tradicionales no pueden ofrecer.

Latencia

- Tiempo que tarda el sistema en responder a una peticion
- Big Data requiere baja latencia: resultados en milisegundos, no horas

Throughput (rendimiento)

- Cantidad de datos procesados por unidad de tiempo (ej: 1 millon de eventos/seg)
- Un sistema con alto throughput procesa mas datos con los mismos recursos

Tolerancia a fallos

- En un cluster de 1.000 maquinas, alguna fallara cada dia — es inevitable
- El sistema debe continuar funcionando aunque fallen nodos individuales

Apache Spark resuelve esto con el linaje de RDDs: si un bloque se pierde, se recalcula

Retos de Analisis: Calidad, Integracion y Heterogeneidad

Tener muchos datos no sirve de nada si son incorrectos, incompletos o incompatibles entre si.

Calidad de datos (Data Quality)

- Datos sucios: valores nulos, duplicados, formatos incorrectos, registros corruptos
- Regla del mundo real: hasta el 80% del tiempo se dedica a limpiar datos

Heterogeneidad de los datos

- Estructurados (tablas SQL), semiestructurados (JSON, XML) y no estructurados (imagenes, audio, texto)
- Cada formato requiere tratamiento diferente antes de poder analizarlo

Integracion de fuentes

- Los datos vienen de CRM, sensores, redes sociales, logs de servidor...
- Hay que unificar esquemas, resolver conflictos y construir una vista coherente

El proceso ETL (Extract, Transform, Load) es critico y suele ser el mas complejo

Infraestructura de Big Data: Dónde viven tus datos y procesamiento

Una vez entendemos los retos, hay que decidir **dónde va a vivir** y **procesarse** la **infraestructura**.

On-Premise (en las instalaciones propias)

- Los servidores son físicos y están en el CPD (Centro de Procesamiento de Datos) de la empresa
- **Control total** sobre los datos – importante en banca, sanidad y defensa

Costes fijos elevados: hardware, electricidad, personal técnico, mantenimiento

Escalar requiere tiempo: comprar, instalar y configurar nuevas máquinas

Cloud (nube pública: AWS, Azure, GCP)

- Los servidores son **virtuales** y gestionados por un proveedor externo
- **Escala en minutos:** se añaden nodos con un clic o de auomátic a de forma
- **Modelo pago por uso:** pagas solo lo que consumes, sin inversión inicial

Tendencia actual: cloud o arquitectura híbrida (parte on-prem, parte cloud)

Combinación óptima: Datos sensibles On-Prem, Procesamiento de picos en Cloud

Criterios clave para elegir infraestructura:

Criterio	On-Premise (Instalaciones)	Cloud (Nube)
Costes	**On-Prem:** inversión inicial alta (**CapEx**).	**Cloud:** coste variable por uso (**OpEx**).
Escalabilidad	**On-Prem:** lenta, planificada.	**Cloud:** inmediata, automatica (**auto-scaling**)
Seguridad y Control	**On-Prem:** control total.	**Cloud:** depende del contrato y certificaciones del proveedor
Mantenimiento	**On-Prem:** equipo interno.	**Cloud:** gestionado por el proveedor
Servicios Big Data disponibles	**Cloud:** Databricks, AWS EMR, Azure HDInsight, Google Dataproc — listos en minutos.	

Para este curso: entorno local (modo standalone) que simula un cluster real

Resumen: Los 4 Grandes Retos Tecnicos del Big Data

Antes de escribir una sola linea de codigo, es fundamental entender a que nos enfrentamos:

1. Almacenamiento

- Los datos no caben en un solo disco. Necesitamos sistemas distribuidos como HDFS

2. Procesamiento

- Hay que procesar rapido (baja latencia), mucho (alto throughput) y sin interrupciones (tolerancia a fallos)

3. Analisis

- Los datos reales son sucios, heterogeneos y vienen de muchas fuentes. La calidad es un reto constante

4. Infraestructura

- Elegir entre on-premise (control, coste fijo) y cloud (agilidad, pago por uso)

01

BLOQUE PRÁCTICO

Identifica retos, compara arquitecturas y evalua tu comprension

Actividad Práctica

Ejercicio 1 — Identifica los cuellos de botella .

Objetivo del ejercicio

- Analizar una arquitectura de datos real y detectar los 4 retos tecnicos vistos en teoria

Escenario: TiendaMax (cadena de supermercados)

- 500 tiendas generan 10 millones de transacciones de venta al dia
- Un solo servidor SQL con 2 TB de capacidad almacena todos los datos
- Los informes de ventas tardan mas de 30 minutos en ejecutarse
- Cuando el servidor se reinicia, hay 2 horas sin acceso a datos en toda la empresa

Tu tarea: responde por escrito

- Cual es el reto de ALMACENAMIENTO principal? Como lo solucionarias?
- Que problema de PROCESAMIENTO tiene? Es latencia o throughput?
- Que fallo de TOLERANCIA A FALLOS existe? Propone una solucion tecnica
- On-Premise o Cloud para TiendaMax? Justifica con 2 argumentos

Pista: usa los 4 grandes retos del Big Data como guia de analisis

Actividad Práctica

Actividad Práctica

IMPULSO_06
FORMACIÓN Y FUTURO

Ejercicio 2 — HDFS vs. Almacenamiento Tradicional

Objetivo del ejercicio

- Construir una tabla comparativa razonada entre HDFS y almacenamiento RAID tradicional

Rellena esta tabla comparativa con lo visto en teoria:

- ESCALABILIDAD: RAID (vertical, comprar discos mas grandes) vs. HDFS (horizontal, anadir nodos)
- TOLERANCIA: RAID-5 (1 disco puede fallar) vs. HDFS (replica x3, varios nodos pueden fallar)
- COSTE: RAID (hardware especializado, caro) vs. HDFS (commodity hardware, barato)
- RENDIMIENTO: RAID (bueno para ficheros pequenos) vs. HDFS (optimo para ficheros grandes +128 MB)
- TIPO DE DATOS: RAID (cualquier archivo) vs. HDFS (ficheros grandes, append-only)

Preguntas de reflexion:

- Por que HDFS NO es bueno para ficheros pequenos?
- Si tienes 1 PB de logs de servidor, usarias RAID o HDFS? Por que?
- En que caso seguirias usando almacenamiento tradicional en una empresa Big Data?

Pista: HDFS divide cada fichero en bloques de 128 MB y los replica en 3 nodos distintos

Actividad Práctica

Actividad Práctica

Ejercicio 3 — Quiz de Comprensión

Preguntas del quiz — responde en tu cuaderno

1. Que es la latencia y por que es critica en Big Data? Pon un ejemplo real
2. Explica la diferencia entre escalado vertical y escalado horizontal
3. Que significa que HDFS replica los datos x3? Que problema resuelve?
4. Nombra 3 fuentes de datos heterogeneas que podria tener un banco
5. Cual es la regla del 80% en proyectos de datos? Por que es tan alta?
6. Una startup necesita procesar 500 GB diarios con presupuesto limitado. On-Prem o Cloud?
7. Que ventaja tiene el modelo OpEx (pago por uso) frente al CapEx (inversion inicial)?

Actividad Práctica

¡Gracias!

[Preguntas · Comentarios]

Dia 2 · Sesion 1 completada ✅ ·