Seguridad, Privacidad y Gobernanza en Big Data

[Módulo 1 · Sesión 2 · Día 2]

Procesamiento Big Data con Scala

02

BLOQUE TEÓRICO

Seguridad, privacidad y gobernanza en entornos Big Data

📋 Agenda — Sesión 2

🧠 Bloque Teórico

- Amenazas de seguridad en entornos Big Data
- Privacidad: GDPR y normativa espanola (LOPD)
- Estrategias de proteccion: cifrado, autenticacion, autorizacion
- Gobernanza de datos y vision general del curso

💻 Bloque Práctico

- Practica 1: Analisis de una brecha de seguridad real
- Practica 2: Diseniar una politica de seguridad para un proyecto
- Practica 3: Evaluacion formativa inicial (cuestionario repaso)

Por que la seguridad es critica en Big Data

Los datos masivos son un activo extraordinariamente valioso — y por eso son tambien un objetivo prioritario para los atacantes.

El volumen amplifica el riesgo

- Una brecha en un sistema tradicional expone miles de registros. En Big Data, expone millones
- Ejemplo: la brecha de Yahoo (2016) afecto a 3.000 millones de cuentas — mayor brecha de la historia

Los datos de Big Data son especialmente sensibles

- Contienen informacion personal (nombres, ubicaciones, habitos), financiera y de salud
- El cruce de fuentes permite perfilar a personas con un nivel de detalle sin precedentes

La regulacion impone obligaciones legales

- El GDPR (Europa) y la LOPD (Espana) establecen multas de hasta 20 millones de euros o el 4% de la facturacion anual
- Ignorar la seguridad no es solo un riesgo tecnico — es un riesgo legal y reputacional

Regla de oro: la seguridad no es una capa que se anade al final — debe diseniarse desde el primer dia

Principales Amenazas de Seguridad en Entornos Big Data

Los sistemas Big Data son complejos y distribuidos, lo que multiplica la superficie de ataque respecto a sistemas tradicionales.

Acceso no autorizado

- Atacantes que obtienen credenciales validas para acceder a datos confidenciales
- En clusters con muchos usuarios, el control de acceso es critico y a menudo mal configurado

Ataques de denegacion de servicio (DoS/DDoS)

- Saturar los nodos del cluster para interrumpir el procesamiento de datos critico para el negocio

Principales Amenazas de Seguridad en Entornos Big Data

IMPULSO_06
FORMACIÓN Y FUTURO

Fuga de datos (Data Leakage)

- Datos sensibles exportados por error o de forma maliciosa fuera del entorno seguro
- En pipelines complejos, los datos pasan por multiples sistemas — cualquiera puede ser el punto de fuga

Inyeccion de datos maliciosos (Data Poisoning)

- Un atacante introduce datos falsos en el pipeline para corromper los modelos de ML o los informes de negocio

Amenazas internas (Insider Threats)

- Empleados con acceso legitimo que filtran, roban o danan datos intencionada o accidentalmente

En entornos Big Data, la mayoria de brechas ocurren por configuraciones incorrectas, no por ataques sofisticados

GDPR: El Reglamento General de Proteccion de Datos

El GDPR (General Data Protection Regulation) es la normativa europea mas importante sobre privacidad de datos. En vigor desde mayo de 2018, afecta a cualquier empresa que procese datos de ciudadanos europeos.

Principios fundamentales del GDPR

- Licitud y transparencia: los datos solo se pueden tratar con base legal y el usuario debe saberlo
- Limitacion de finalidad: los datos recogidos para un fin no se pueden usar para otro diferente
- Minimizacion: solo recoger los datos estrictamente necesarios para el proposito declarado
- Exactitud: mantener los datos actualizados y corregir o eliminar los inexactos
- Limitacion de plazo: no conservar los datos mas tiempo del necesario

Derechos del ciudadano que afectan al diseno de sistemas Big Data

- Derecho al acceso: cualquier persona puede pedir que le muestren sus datos
- Derecho de supresion (derecho al olvido): puede pedir que se borren sus datos del sistema
- Derecho a la portabilidad: puede pedir sus datos en formato legible por maquina

Implicacion practica: en Big Data, implementar el "derecho al olvido" es tecnicamente muy complejo si los datos estan en HDFS o Parquet sin una capa de gobernanza

LOPD, Cifrado, Autenticacion y Autorizacion

Espana tiene su propia ley de proteccion de datos, la LOPD-GDD, que desarrolla y complementa el GDPR a nivel nacional.

LOPD-GDD (Ley Organica de Proteccion de Datos y Garantia de Derechos Digitales)

- Aprobada en 2018, adapta el GDPR al ordenamiento juridico espanol
- Añade protecciones especificas: derecho al olvido en redes sociales, desconexion digital laboral, proteccion de menores
- La AEPD (Agencia Espanola de Proteccion de Datos) es el organismo regulador en Espana

Cifrado (Encryption)

- Datos en reposo (at rest): el contenido almacenado en HDFS o S3 se cifra con AES-256
- Datos en transito (in transit): las comunicaciones entre nodos del cluster usan TLS/SSL

LOPD, Cifrado, Autenticacion y Autorizacion

Autenticacion: verificar QUIEN accede

- Kerberos: protocolo de autenticacion estandar en entornos Hadoop — cada usuario y servicio tiene un ticket
- LDAP / Active Directory: directorio centralizado de usuarios y contrasenas corporativas

Autorizacion: verificar QUE puede hacer cada usuario

- Apache Ranger: politicas de acceso a nivel de tabla, columna o fila en el cluster
- RBAC (Role-Based Access Control): los permisos se asignan por rol, no por usuario individual

Gobernanza de Datos: Pilar Fundamental de Big Data

La **gobernanza de datos** es el conjunto de políticas, procesos y estándares que garantizan que los datos de una organización sean fiables, seguros y usados correctamente.

¿Por qué es necesaria la gobernanza?

ANTES (Sin Gobernanza)

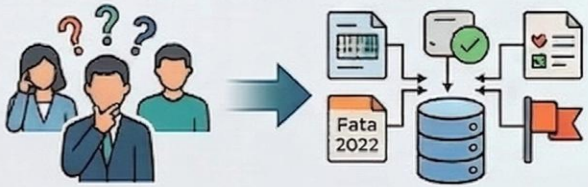

Datos inconsistentes: Definiciones y formatos variados.
Riesgo legal por incumplimiento.

AHORA (Con Gobernanza)

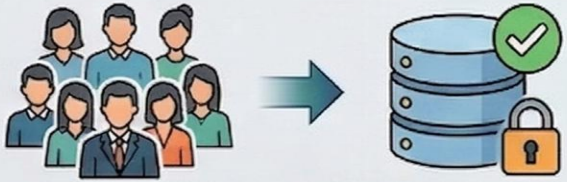

Decisiones fiables basadas en datos correctos.
Cumplimiento legal asegurado.
Alta calidad de datos.

Roles Clave en Gobernanza de Datos

Data Owner
Define acceso y propósito.
Responsable de negocio

Data Steward
Garantiza calidad, documentación y cumplimiento.
Perfil técnico-negocio

Data Engineer
Construye pipelines de datos, mueve y transforma

Data Governance Officer
Coordina la estrategia a nivel organizativo

Herramientas de Gobernanza

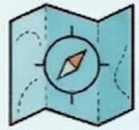

Apache Atlas
Catálogo de datos y linaje.
Rastrea origen y fiujo

Atlas

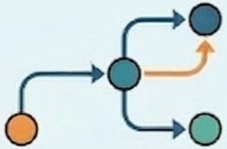

Apache Ranger
Control de acceso granular.
Permisos a nivel de tabla, columna y fila

Vision General del Curso: Que Aprenderemos

Ahora que conoceis los fundamentos de Big Data y sus retos, es el momento de ver el mapa completo del camino que tenemos por delante.

Modulo 1 — Introduccion al Big Data (esta semana)

- Las 4 Vs, ecosistema, retos tecnicos, seguridad y gobernanza — ya completado

Modulo 2 — Fundamentos de Scala (dias 3-10)

- El lenguaje de programacion que usaremos para interactuar con Spark: sintaxis, colecciones, POO, programacion funcional

Modulo 3 — Apache Spark (dias 11-20)

- El motor de procesamiento distribuido: RDDs, DataFrames, Spark SQL, Streaming, optimizacion y MLlib

Modulo 4 — Analisis y Visualizacion (dias 21-22)

- Exploracion de datos a gran escala, visualizaciones y creacion de informes y dashboards

Modulo 5 — Proyectos de Big Data (dias 23-28)

- Arquitectura, mejores practicas, integracion con el ecosistema, cloud y proyecto final

Resumen del Bloque Teorico — Dia 2

Seguridad: la regla de oro

- La seguridad se diseña desde el primer dia, no se añade al final
- Las amenazas mas comunes no son sofisticadas: son configuraciones incorrectas y accesos no controlados

GDPR y LOPD: compliance desde el diseno

- Todo sistema Big Data que trate datos de ciudadanos europeos debe cumplir el GDPR
- Derechos del ciudadano (acceso, olvido, portabilidad) tienen implicaciones tecnicas directas en el diseño.

Proteccion en 3 capas

- Cifrado: datos en reposo (AES-256) y en transito (TLS/SSL)
- Autenticacion (Kerberos, LDAP): verificar la identidad de quien accede
- Autorizacion (Ranger, RBAC): controlar que puede hacer cada usuario identificado

Gobernanza: el pegamento organizativo

- Sin Data Owners, Stewards y politicas claras, el dato tecnico mas perfecto pierde valor

02

BLOQUE PRÁCTICO

Analiza una brecha, disenia una politica de seguridad y evalua tus conocimientos

Actividad Práctica

Ejercicio 1 — Analisis de una brecha de seguridad

Contexto del ejercicio

- En 2017, Equifax (empresa de credito financiero) sufrio una brecha que expuso datos personales de 147 millones de personas
- Datos expuestos: nombres, numeros de la Seguridad Social, fechas de nacimiento, direcciones y numeros de tarjeta de credito
- La brecha se produjo por una vulnerabilidad conocida en Apache Struts que Equifax no habia parcheado en mas de 2 meses
- Coste total: mas de 1.400 millones de dolares en multas, compensaciones y mejoras de seguridad

Tu tarea: analiza el caso usando lo visto en teoria

- Que tipo de amenaza de seguridad fue esta brecha? (acceso no autorizado, DoS, fuga de datos...)
- Que principio del GDPR se vulnero principalmente? Razona tu respuesta
- Que mecanismo de proteccion habria podido prevenir la brecha? (cifrado, autenticacion, autorizacion, parcheo...)
- Si Equifax hubiera tenido Apache Ranger, habria servido para prevenir esto? Por que si o por que no?
- Que rol de gobernanza (Data Owner, Steward, Engineer) tenia la responsabilidad directa de aplicar el parche?

Actividad Práctica

Actividad Práctica

Ejercicio 2 — Diseña una Politica de Seguridad

Contexto: DataHealth, una startup de analisis de datos clinicos

- DataHealth analiza historiales medicos de hospitales espanoles para detectar patrones de enfermedad
- Procesa datos de 500.000 pacientes: diagnosticos, medicacion, resultados de laboratorio y datos demograficos
- Su cluster Spark esta en la nube (AWS) y tiene 15 ingenieros de datos, 8 data scientists y 30 medicos investigadores
- Hasta ahora no tienen ninguna politica de seguridad formalizada — cualquier empleado puede acceder a todos los datos

Tu tarea: disenia una politica basica de seguridad para DataHealth

- CIFRADO: que datos cifrarias en reposo y en transito? Con que herramientas?
- AUTENTICACION: que mecanismo de autenticacion usarias? Por que?
- AUTORIZACION: define al menos 3 roles diferentes y que datos puede ver cada uno
- GDPR: cuales son las 3 obligaciones GDPR mas importantes para DataHealth dado que trata datos de salud?
- GOBERNANZA: quien seria el Data Owner de los datos de pacientes? Y el Data Steward?

Los datos de salud son categoria especial bajo el GDPR (Art. 9) y requieren protecciones adicionales

Actividad Práctica

¡Gracias!

[Preguntas · Comentarios]

Sesión 2 · completada ✅ ·